Matriz de optimización de costos

Asignación de modelo de Cohere por tarea del ecosistema, con costo estimado por documento y ahorro frente a usar siempre el modelo más grande.

1. Precios de referencia (USD por 1 millón de tokens)

Modelo	Entrada	Salida	Fuente
command-r7b	$0.0375	$0.15	puter.com (jun-2026), fuente secundaria
command-r-08-2024	$0.15	$0.60	puter.com (jun-2026), fuente secundaria
command-r-plus-08-2024	$2.50	$10.00	cohere.com/pricing (sección legacy) y puter.com

Importante: los precios se consultaron al armar este documento y Cohere puede cambiarlos; la página oficial no mostraba command-r-08-2024 ni R7B, por lo que esos dos valores provienen de una fuente secundaria. Verificar en el dashboard de Cohere antes de usarlos como presupuesto.

2. Supuestos de volumen y tokens (estimados, no medidos)

Tarea	Documentos/mes	Tokens entrada	Tokens salida
Extracción de datos del VEP/boleta	200	1.200	120
Recordatorio al cliente (mensaje corto)	200	350	150
Informe mensual (resumen)	20	1.500	300

200 documentos/mes y 20 clientes con informe son un escenario de estudio chico; ajustar al volumen real.

3. Matriz: modelo por tarea

Tarea	Modelo asignado	Costo/doc	Si usara solo R+	Justificación
Extracción de datos (CUIT, monto, impuesto)	command-r-plus-08-2024 (implementado)	$0.00420	$0.00420	En las pruebas, command-r-08-2024 truncó un CUIT; R+ lo leyó completo. Exactitud antes que costo en el dato que busca al cliente.
Extracción - cascada propuesta	command-r-08-2024 primero; si el CUIT no tiene 11 dígitos, reintento con R+	$0.00025 (+R+ en reintentos)	$0.00420	Usa el filtro length(cuit)=11 ya existente como disparador del escalado. Supuesto: 30% de reintentos.
Recordatorio al cliente (E2)	Plantilla de Make con variables, sin llamada a IA (implementado). Opcional: command-r-08-2024 si se quiere redacción personalizada	$0.00000 (plantilla)	$0.00237	Mensaje fijo con nombre, impuesto y monto; ya fue aprobado por el contador antes de enviarse. Una IA solo aportaría tono personalizado.
Informe mensual (diseñado, no implementado en esta entrega)	command-r-08-2024	$0.00040	$0.00675	Resumen de números ya calculados en Airtable; el modelo solo redacta.
Clasificación previa (opcional)	command-r7b	$0.00006	-	Podría descartar archivos que no son VEP antes de la extracción.

4. Ahorro estimado

Estrategia	Costo mensual (USD)	Ahorro vs. todo en R+
A. Todo con command-r-plus (línea base)	$1.45	-
B. Diseño: R+ solo extracción, R para redacción	$0.88	40%
C. Propuesta: cascada R → R+ (30% reintentos) + R redacción	$0.34	77%
D. Implementado hoy: R+ en extracción, recordatorio con plantilla (sin IA), sin informe	$0.84	36% (vs. extracción+recordatorio todo en R+: $1.31)

La fila D es lo que realmente corre hoy: la extracción usa el modelo grande y el recordatorio no gasta tokens. Los montos son muy bajos en términos absolutos por el volumen; el criterio de diseño es el que escala: **modelo grande solo donde un error cuesta** (identificar al cliente), modelo chico donde la salida pasa por revisión humana.

5. Otras palancas de costo

• **max_tokens = 300** y **temperature = 0** en la extracción: salida corta y determinística.

• **Minimización de entrada:** el módulo Tools limpia el texto antes de enviarlo; menos tokens y menos datos expuestos.

• **Filtros antes de la IA y después:** los documentos descartados no generan llamadas posteriores.

• **Trigger programado cada 15 minutos** (Watch Files): no consume operaciones si no hay archivos nuevos.

• Límite no medido: no se cargó un tablero de consumo real. Con 5 corridas de prueba conviene revisar el uso en el dashboard de Cohere y recalibrar los supuestos.

Fuentes: cohere.com/pricing; developer.puter.com/tutorials/cohere-api-pricing (actualizado 23-jun-2026).